

Raha 数据检测功能模块与任务计划

1. 文档说明

1.1 文档目的

本文档依据 `Raha数据检测概要设计-202607141718.md`，将 Raha 数据检测工程拆分为可开发、可测试、可交付的功能模块，并给出模块优先级、依赖关系、任务清单、迭代顺序和验收门槛。

本文档用于后续：

- 创建研发任务和测试任务。
- 安排模块开发顺序和并行工作流。
- 明确每个阶段的交付物和完成标准。
- 控制工程范围，确保只实现数据检测，不进入数据纠正。
- 作为详细设计文档拆分和代码实现的任务索引。

1.2 设计依据

文档	用途
<code>doc\\20260714\\Raha数据检测概要设计-202607141718.md</code>	功能模块和任务拆分的直接依据
<code>doc\\20260714\\Raha-Java工程化与SparkUDF检测方案-202607141549.md</code>	Java、Spark、FMDB 和依赖约束依据
<code>design\\raha-baran-fast.pdf</code>	并行任务和只读中间结果设计依据
<code>design\\baran-effective-error-correction-unified-context-transfer-learning-2020.pdf</code>	上下文特征和历史迁移思路依据
<code>F:\\ai-code\\raha\\raha-master\\raha\\detection.py</code>	Raha Python demo 行为对齐依据

1.3 范围约束

所有任务必须遵循以下边界：

1. 工程只检测疑似错误单元格。
2. 工程不生成修复值、纠正候选或清洗后数据。
3. 工程不回写和覆盖输入表。
4. 主处理形态是表级 Spark 批处理。
5. UDF 只作为任务提交和平台适配入口。
6. `lib2.12` 目录不作为依赖来源。
7. 只从 `lib` 选择与 Spark 3.3.1、Scala 2.12 兼容的唯一依赖版本组合。

2. 优先级定义


优先级	定义	进入条件	完成目标
P0	阻塞性基础和最小检测闭环	项目启动后立即执行	能读取数据、运行基础策略、生成特征并输出可解释检测结果
P1	Raha 核心学习能力	P0 闭环稳定	补齐聚类、采样、标注、标签传播和列级模型
P2	生产化和平台接入	P1 流程可验证	完成 Spark 并行、失败恢复、FMDB 适配、UDF、性能和安全
P3	增强和优化能力	生产主流程稳定	增加历史策略过滤、知识库、文本特征和算法对比


优先级判断原则：


- 没有该模块就无法形成检测闭环的任务归入 P0。
- 属于 Raha 论文核心学习流程，但可以在基础策略闭环之后补齐的任务归入 P1。
- 不改变核心检测语义，主要解决规模、平台和运维问题的任务归入 P2。
- 依赖外部资源、历史数据或额外算法验证的增强任务归入 P3。

3. 功能模块全景

3.1 模块依赖图







3.2 模块清单

模块编号	功能模块	优先级	主要依赖	核心交付物
M01	工程骨架与依赖治理	P0	无	Maven 工程、POM、编码和测试基线
M02	配置与参数校验	P0	M01	任务、策略、特征、模型和资源配置对象
M03	核心领域对象	P0	M01	数据集、单元格、策略命中、特征、标签和结果对象
M04	任务编排与状态管理	P0	M02、M03	任务状态机、阶段编排、幂等和重跑骨架
M05	数据读取与快照	P0	M02、M03	Spark 数据读取、稳定行标识、模式哈希和快照
M06	数据画像	P0	M05	列类型、频率、长度、字符和分布画像

模块编号	功能模块	优先级	主要依赖	核心交付物
M07	中间结果与仓储接口	P0	M03、M04	任务、策略、特征、标签、模型和结果仓储接口
M08	策略框架与策略计划	P0	M02、M06、M07	策略接口、策略生成器、稳定策略标识和计划表
M09	OD 离群策略	P0	M06、M08	频率、数值和分位数离群检测
M10	PVD 模式策略	P0	M06、M08	字符、长度、空值、类型和格式异常检测
M11	RVD 关系策略	P0	M06、M08	列对依赖、一对多和共现冲突检测
M12	特征工程	P0	M09、M10、M11	特征字典、稀疏向量和上下文基础特征
M13	基础检测与结果解释	P0	M12、M07	规则加权检测、原因结构和检测结果表
M14	日志、指标与异常基础	P0	M04	关联日志、阶段指标、错误编码和异常上下文
M15	基础测试与 Python 对齐	P0	M09 至 M14	单元测试、端到端样例和 demo 对齐报告
M16	列内聚类	P1	M12	聚类接口、层次聚类实现和聚类成员结果
M17	主动采样与标注任务	P1	M16、M07	元组采样、标注预算和标注任务状态
M18	标签仓储与标签传播	P1	M16、M17	直接标签、传播标签、冲突处理和来源追踪
M19	列级模型训练与预测	P1	M12、M18	训练数据构建、分类器、阈值和预测器
M20	模型版本与发布管理	P1	M19、M07	模型元数据、特征版本、发布和回滚
M21	Raha 训练、采样和检测服务	P1	M16 至 M20	三类业务服务和完整 Raha 流程
M22	评测服务	P1	M19、M21	精确率、召回率、F1 和阈值评估
M23	Spark 并行与资源治理	P2	M21	策略级、列级、分区级并行和并发限制
M24	检查点、恢复与幂等增强	P2	M04、M07、M23	阶段检查点、断点续跑和重复结果去重

模块编号	功能模块	优先级	主要依赖	核心交付物
M25	FMDB 数据与结果适配	P2	M07、M21	FMDB 读取、写入、模型存储和审计适配
M26	FMDB UDF 入口	P2	M25、M21	训练、检测和采样表级 UDF
M27	安全、脱敏与审计	P2	M14、M25	敏感值保护、权限检查和操作审计
M28	性能、容量与稳定性	P2	M23、M24	性能基准、大表测试、宽表测试和资源建议
M29	历史画像与策略过滤	P3	M06、M22	历史字段画像、字段相似度和策略选择
M30	KBVD 知识策略	P3	M08、M25	字典、主数据和知识关系检测插件
M31	文本特征增强	P3	M12、M19	文本列稀疏特征和一致性验证
M32	备选聚类与分类器	P3	M16、M19、M22	近似聚类、决策树和梯度提升对比

4. P0 功能模块

4.1 M01 工程骨架与依赖治理

功能范围

- 创建单 Maven 工程和标准目录。
- 固定 Java 8、Spark 3.3.1 和 Scala 2.12 基线。
- 只从 1ib 目录选择依赖。
- 排除 Spark 4 _2.13 和多版本重复 jar。
- 建立 UTF-8 无 BOM、LF、中文注释和日志规范。
- 建立单元测试、集成测试和构建命令。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T001	创建 Maven 工程和包目录	P0	S	无	工程可编译，目录符合概要设计
T002	固定 JDK、Spark 和 Scala 版本	P0	S	T001	POM 中版本唯一且集中管理
T003	盘点并建立本地 jar 白名单	P0	M	T002	不加载 Spark 4 和重复版本
T004	验证 MLlib 是否由平台提供	P0	M	T002	形成 MLlib 使用或降级结论
T005	建立编译、测试和依赖冲突检查	P0	M	T003	构建可自动发现重复类和版本冲突

完成标准

- `mvn test` 可执行。
- classpath 不包含 `lib2.12` 目录。
- Spark 主组件只使用 3.3.1 `_2.12`。
- MLlib 可用性有明确结论和兜底方案。

4.2 M02 配置与参数校验

功能范围

- 任务类型、数据源、行标识和结果位置配置。
- 策略族、策略上限、列白名单和列对上限配置。
- 特征、聚类、采样、标签传播和模型配置。
- Spark 并行、缓存、超时和失败容忍配置。
- 配置默认值、版本、序列化和校验错误编码。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T006	定义任务级配置对象	P0	M	T001	支持评测、训练、采样和检测模式
T007	定义策略、特征和模型配置	P0	M	T006	配置字段与概要设计一致
T008	定义资源和失败容忍配置	P0	S	T006	支持并发、超时、重试和失败阈值
T009	实现配置校验器	P0	M	T007、T008	非法输入返回稳定错误编码
T010	实现配置版本和摘要哈希	P0	S	T007	同一配置产生稳定版本标识

4.3 M03 核心领域对象

功能范围

建立不依赖 FMDB 具体实现的核心对象：

- RahaDataset。
- ColumnProfile。
- CellCoordinate 和 CellValue。
- StrategyPlan 和 StrategyHit。
- FeatureDictionary 和 SparseFeatureRow。
- CellLabel 和 ClusterAssignment。
- RahaColumnModel 和 DetectionResult。
- RahaJob 和 RahaStage。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T011	定义数据集、列和单元格对象	P0	M	T001	对象可定位到稳定单元格
T012	定义策略计划和命中对象	P0	M	T011	策略配置和命中原因可追溯
T013	定义特征、聚类和标签对象	P0	M	T011	支持稀疏特征和标签来源
T014	定义模型和检测结果对象	P0	M	T013	结果不含任何修复值字段
T015	定义任务、阶段和状态枚举	P0	S	T011	状态转换可以被任务编排使用

4.4 M04 任务编排与状态管理

功能范围

- 创建任务和阶段。
- 管理任务状态和阶段状态。
- 控制阶段依赖和失败分支。
- 生成 jobId、stageId、attemptId 和幂等键。
- 为后续检查点和恢复预留接口。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T016	实现任务状态机	P0	M	T015	非法状态跳转被拒绝
T017	实现阶段编排接口	P0	L	T016、T009	可串联读取、策略、特征和检测阶段
T018	实现任务幂等键	P0	M	T010、T016	重复提交可识别同一请求
T019	实现阶段失败和终止规则	P0	M	T017	支持失败阈值和可恢复状态

4.5 M05 数据读取与快照

功能范围

- 通过抽象接口读取 Spark `Dataset<Row>`。
- 识别和校验稳定行标识。
- 生成输入快照和模式哈希。
- 统一字段类型和可检测字段集合。
- 禁止在检测流程中修改原始输入数据。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T020	定义数据加载接口	P0	S	T011	核心层不依赖 FMDB 具体类
T021	实现文件或测试数据加载器	P0	M	T020	本地测试数据可读取为 Spark 数据集
T022	实现行标识校验	P0	M	T021	缺失和重复行标识可被发现
T023	实现模式哈希和快照元数据	P0	M	T021	相同模式产生稳定哈希
T024	实现值哈希和脱敏基础工具	P0	M	T011	日志和结果可避免暴露完整敏感值

4.6 M06 数据画像

功能范围

- 空值和非空率画像。
- 不同值数量、值频率和重复率画像。
- 数值统计和分位数画像。
- 字符集合、长度和类型比例画像。
- 模式摘要和策略生成所需的列元数据。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T025	实现基础列画像	P0	M	T021	输出行数、空值和不同值统计
T026	实现数值和分位数画像	P0	M	T025	可识别数值列及长尾分布
T027	实现字符、长度和类型画像	P0	L	T025	为 PVD 生成稳定画像
T028	实现画像持久化接口	P0	M	T025、T027	画像可按快照和列读取

4.7 M07 中间结果与仓储接口

功能范围

定义并实现开发期仓储接口，后续由 FMDB 适配替换或扩展：

- 任务仓储。
- 阶段仓储。
- 策略计划和策略命中仓储。
- 特征字典和特征仓储。
- 聚类、采样和标签仓储。
- 模型元数据和检测结果仓储。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T029	定义统一仓储接口和事务边界	P0	L	T011 至 T015	核心服务只依赖仓储接口
T030	实现开发期文件或内存仓储	P0	M	T029	本地端到端流程可保存中间结果
T031	实现结果主键和去重规则	P0	M	T029	同一批次重写不产生重复有效记录
T032	实现中间结果版本字段	P0	M	T029	结果可追溯配置、快照和阶段版本

4.8 M08 策略框架与策略计划

功能范围

- 统一 DetectionStrategy 接口。
- 统一策略输入、输出、日志、超时和异常语义。

- 根据画像生成策略配置。
- 生成确定性的 strategyId。
- 支持策略白名单、黑名单、上限和优先级。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T033	定义策略接口和执行上下文	P0	M	T012、T029	所有策略使用统一契约
T034	实现策略计划生成器	P0	L	T027、T033	相同画像和配置生成相同计划
T035	实现策略标识和配置哈希	P0	S	T034	策略结果可稳定去重
T036	实现策略超时和失败隔离	P0	M	T033、T019	单策略失败不会破坏状态一致性
T037	实现策略运行摘要	P0	M	T033	输出命中数、耗时和失败原因

4.9 M09 OD 离群策略

功能范围

- 低频值和频率桶异常。
- 数值均值和标准差距离异常。
- 分位数和四分位距异常。
- 阈值配置组合和画像适用性判断。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T038	实现值频和低频策略	P0	M	T033、T025	可输出低频候选及原因
T039	实现数值距离策略	P0	M	T026、T033	可输出数值离群候选及分数
T040	实现分位数离群策略	P0	M	T026、T033	长尾数据具备稳定检测行为
T041	完成 OD 单元测试	P0	M	T038 至 T040	覆盖正常、离群、空值和不可解析场景

4.10 M10 PVD 模式策略

功能范围

- 字符集合异常。

- 长度异常。
- 空值、空白值和特殊占位值异常。
- 数字、字母、中文和符号类型异常。
- 可配置日期、时间、电话和编号格式检测。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T042	实现字符集合策略	P0	M	T027、T033	可识别列内少数字符模式
T043	实现长度异常策略	P0	M	T027、T033	可识别长度分布异常
T044	实现空值和占位值策略	P0	M	T025、T033	区分空值、空白和特殊占位值
T045	实现类型和格式策略	P0	L	T027、T033	输出类型或格式异常原因
T046	完成 PVD 单元测试	P0	M	T042 至 T045	覆盖多字符类型和空值边界

4.11 M11 RVD 关系策略

功能范围

- 枚举允许的单列到单列依赖。
- 检测同一左值对应多个右值的冲突。
- 输出目标单元格、依赖方向和冲突统计。
- 控制宽表列对数量和执行成本。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T047	实现列对筛选和上限控制	P0	M	T034、T027	宽表不会无限枚举列对
T048	实现一对多冲突检测	P0	L	T033、T047	可定位依赖冲突单元格
T049	实现冲突分数和原因结构	P0	M	T048	结果可解释冲突规模和方向
T050	完成 RVD 单元测试	P0	M	T048、T049	覆盖唯一映射、冲突和空值场景

4.12 M12 特征工程

功能范围

- 将策略命中转换成单元格二值特征。

- 生成策略族命中数量和分数摘要。
- 生成值长度、字符类型和值频率桶等上下文基础特征。
- 删除无区分度特征。
- 生成稳定特征字典和稀疏向量。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T051	实现策略命中特征组装	P0	L	T038 至 T050	每个单元格可生成策略二值向量
T052	实现上下文基础特征	P0	L	T025 至 T027	生成值和列内上下文特征
T053	实现无区分度特征过滤	P0	M	T051、T052	全零和常量特征被移除
T054	实现特征字典和版本	P0	M	T053、T032	训练和检测可使用同一字典
T055	实现稀疏向量持久化	P0	L	T054、T029	特征可按列和批次读取

4.13 M13 基础检测与结果解释

功能范围

在列级机器学习模型完成前，使用规则加权融合作为最小检测闭环：

- 按策略族和策略可靠度计算候选分数。
- 使用配置阈值输出 `isError`。
- 输出命中策略、原因、特征摘要和版本。
- 明确标记 `fallback` 或 `weighted_rule` 模型类型。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T056	定义基础检测评分规则	P0	M	T051、T052	评分规则可配置和解释
T057	实现基础检测服务	P0	L	T056、T055	输入表可输出单元格检测结果
T058	实现结果解释服务	P0	M	T037、T057	结果可反查策略和原因
T059	实现检测结果持久化	P0	M	T057、T029	结果包含任务、快照和版本信息
T060	校验结果不含纠正字段	P0	S	T059	对象、表和接口均无修复值

4.14 M14 日志、指标与异常基础

功能范围

- 建立统一日志上下文。
- 记录任务和阶段开始、结束、耗时和摘要。
- 记录外部数据访问和异常堆栈。
- 建立错误编码和异常分类。
- 记录策略、特征和检测指标。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T061	定义日志上下文字段	P0	S	T016	日志包含任务、阶段和尝试标识
T062	定义错误编码和异常层次	P0	M	T009、T019	异常可区分参数、数据、策略和存储
T063	接入任务和阶段关键日志	P0	M	T017、T061	核心路径有开始、关键分支和结束日志
T064	接入策略和检测指标	P0	M	T037、T059	可统计命中数、失败数和检测数
T065	建立敏感值日志检查	P0	S	T024、T063	日志不直接输出完整敏感值

4.15 M15 基础测试与 Python 对齐

功能范围

- 建立固定小型脏数据集和真值数据集。
- 对齐 Python demo 的策略生成和特征语义。
- 完成基础策略、特征和检测闭环测试。
- 输出差异说明和已知偏差。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T066	准备固定测试数据集	P0	M	T021	覆盖缺失、格式、离群和依赖冲突
T067	建立 Python demo 基线输出	P0	M	T066	保存策略、特征和检测基线
T068	完成基础策略对齐测试	P0	L	T041、T046、T050、T067	差异有可解释结论

任务编号	任务	优先级	工作量	前置任务	验收结果
T069	完成端到端检测测试	P0	L	T057、T059	验收结束，本地模式可完整运行
T070	输出 P0 验收报告	P0	M	T068、T069	确认检测、定位、解释和复跑成立

5. P1 功能模块

5.1 M16 列内聚类

功能范围

- 定义列聚类统一接口。
- 实现小表层次聚类。
- 支持余弦距离、簇数量和随机种子配置。
- 保存单元格到聚类的映射和聚类版本。
- 处理空特征、单样本和距离不可计算场景。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T071	定义列聚类接口	P1	M	T055	聚类实现可替换
T072	实现层次聚类版本	P1	L	T071	小表聚类结果可复现
T073	实现聚类成员持久化	P1	M	T072、T029	可按列和版本读取聚类成员
T074	实现聚类异常和空结果处理	P1	M	T072	异常列不导致无说明失败

5.2 M17 主动采样与标注任务

功能范围

- 根据聚类标签覆盖程度给元组评分。
- 按标注预算选择待标注元组。
- 生成标注任务和状态。
- 避免重复采样已经标注的元组。
- 保持随机种子可复现。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T075	实现聚类覆盖评分	P1	L	T073	低标签聚类获得更高采样分数
T076	实现元组采样器	P1	M	T075	在预算内输出不重复元组
T077	实现标注任务状态	P1	M	T029、T076	支持待标注、完成、过期和取消
T078	实现真值自动标注适配	P1	M	T077	仅评测模式可由真值生成标签

5.3 M18 标签仓储与标签传播

功能范围

- 保存人工、真值、规则确认和传播标签。
- 实现 `homogeneity` 同质性传播。
- 实现 `majority` 多数传播。
- 记录标签冲突、来源、置信度和权重。
- 保证传播标签不覆盖直接标签。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T079	实现标签仓储	P1	M	T029、T077	标签来源和版本可追溯
T080	实现同质性传播	P1	M	T073、T079	簇内标签一致时正确传播
T081	实现多数传播	P1	M	T073、T079	冲突时记录多数比例
T082	实现传播冲突和权重	P1	M	T080、T081	传播标签权重低于直接标签
T083	完成标签传播测试	P1	M	T080 至 T082	覆盖一致、冲突和无标签场景

5.4 M19 列级模型训练与预测

功能范围

- 按列构造训练集。
- 处理正负类别不平衡。
- 首选 Spark MLlib 逻辑回归。
- 支持无 MLlib 时规则加权降级。
- 按列输出错误分数和阈值判断。
- 处理单类别和无有效特征场景。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T084	实现列级训练数据构建	P1	L	T055、T079、T082	标签和特征可按列关联
T085	实现类别权重和样本权重	P1	M	T084	直接标签与传播标签权重可区分
T086	实现逻辑回归训练器	P1	L	T004、T084	MLlib 可用时完成列级训练
T087	实现规则加权降级训练器	P1	M	T056、T084	MLlib 不可用时闭环仍可运行
T088	实现列级预测器	P1	L	T086 或 T087	输出分数、阈值和模型类型
T089	实现不可训练列处理	P1	M	T084、T088	单类别和空特征列不会生成伪模型

5.5 M20 模型版本与发布管理

功能范围

- 保存列级模型、特征字典、策略计划和模式哈希关系。
- 管理草稿、候选、已发布和已停用状态。
- 支持模型发布、停用和回滚。
- 检测前校验模型与输入模式兼容性。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T090	实现模型元数据仓储	P1	M	T029、T088	模型版本和依赖版本可追溯
T091	实现模型文件保存和加载	P1	L	T086、T090	模型可重启后加载预测
T092	实现发布状态机	P1	M	T090	只有已发布模型可生产使用
T093	实现模式和特征兼容校验	P1	M	T023、T054、T090	不兼容模型被拒绝加载
T094	实现模型回滚	P1	M	T092	可切回前一个已发布版本

5.6 M21 Raha 训练、采样和检测服务

功能范围

- `RahaTrainService` 编排策略、特征、标签传播和模型训练。
- `RahaSampleService` 编排聚类 and 采样任务。
- `RahaDetectService` 加载已发布模型并执行批量预测。
- 服务输出统一任务结果和阶段摘要。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T095	实现训练服务	P1	L	T084 至 T093	可产出候选列级模型
T096	实现采样服务	P1	M	T075 至 T079	可生成待标注任务
T097	实现检测服务	P1	L	T088、T093	可使用已发布模型批量检测
T098	实现统一任务结果	P1	M	T095 至 T097	返回状态、结果位置和摘要

5.7 M22 评测服务

功能范围

- 读取脏表和真值表。
- 计算单元格级精确率、召回率、F1 和平均精确率。
- 比较采样预算、传播方式、分类器和阈值。
- 输出 Python demo 对齐报告。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T099	实现真值差异计算	P1	M	T078	可生成单元格真值标签
T100	实现检测指标计算	P1	M	T097、T099	输出精确率、召回率和 F1
T101	实现阈值对比	P1	M	T100	可选择候选阈值并写模型元数据
T102	完成 Raha 流程对齐测试	P1	L	T095 至 T101	策略、聚类、传播和检测差异可解释
T103	输出 P1 验收报告	P1	M	T102	Raha 核心学习流程验收通过

6. P2 功能模块

6.1 M23 Spark 并行与资源治理

功能范围

- 策略配置级并行。
- 列级特征、聚类、训练和预测并行。
- 大列分区或块级预测。
- 小型配置和字典广播。
- 缓存、持久化、并发和超时控制。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T104	实现策略级并行执行	P2	L	T037、T102	多策略并发且结果幂等
T105	实现列级特征和聚类并行	P2	L	T055、T073	列任务独立执行并可限流
T106	实现列级训练和预测并行	P2	L	T095、T097	多列模型任务可并发
T107	实现分区和块级预测	P2	L	T106	大列预测不收集到Driver
T108	实现缓存和广播大小控制	P2	M	T104 至 T107	超过上限的数据不广播
T109	实现并发和资源限流	P2	M	T104 至 T107	可配置最大策略和列并发数

6.2 M24 检查点、恢复与幂等增强

功能范围

- 每阶段保存输入版本、输出位置、摘要和状态。
- 成功阶段在版本一致时复用。
- 失败阶段支持重试和新尝试记录。
- 防止重复有效结果和模型版本污染。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T110	实现阶段检查点	P2	L	T017、T032	阶段输出和摘要可恢复
T111	实现阶段复用判断	P2	M	T110	版本一致时跳过重复计算
T112	实现失败重试和尝试记录	P2	M	T019、T110	每次尝试可审计
T113	实现部分策略失败恢复	P2	L	T104、T112	可只重跑失败策略
T114	完成幂等和恢复测试	P2	L	T110 至 T113	重跑不产生重复有效记录

6.3 M25 FMDB 数据与结果适配

功能范围

- FMDB 表和 SQL 数据读取。
- FMDB 模式、字段和行标识解析。
- 任务、中间结果、模型元数据和检测结果写入。
- 模型文件和特征字典存储。
- FMDB 外部调用日志和异常处理。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T115	确认 FMDB jar 唯一版本组合	P2	M	T003	形成可运行 classpath 清单
T116	实现 FMDB 数据加载器	P2	L	T020、T115	FMDB 表可读取为 Spark 数据集
T117	实现 FMDB 结果写入器	P2	L	T029、T115	任务和检测结果可落表
T118	实现 FMDB 模型存储	P2	L	T091、T115	模型和字典可保存与加载
T119	完成 FMDB 适配集成测试	P2	L	T116 至 T118	训练和检测可在 FMDB 环境运行

6.4 M26 FMDB UDF 入口

功能范围

- F_DW_RAHATRAN。
- F_DW_RAHADTECT。

- F_DW_RAHASAMPLE。
- 参数解析、权限校验、任务提交和统一结果返回。
- 禁止单元格即时 Raha 检测入口。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T120	确认 UDF 同步或异步调用语义	P2	S	T119	接口返回契约确定
T121	实现训练 UDF	P2	M	T095、T119、T120	可提交训练任务并返回任务信息
T122	实现检测 UDF	P2	M	T097、T119、T120	可提交表级检测任务
T123	实现采样 UDF	P2	M	T096、T119、T120	可生成标注任务
T124	完成 UDF 参数和异常测试	P2	M	T121 至 T123	非法参数和失败结果可追溯

6.5 M27 安全、脱敏与审计

功能范围

- 输入表、结果表和模型目录权限检查。
- 日志和结果中的值脱敏。
- 标注任务最小字段展示。
- 任务提交、模型发布和结果访问审计。
- 结果保留和过期清理。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T125	实现权限校验适配接口	P2	M	T116、T117	无权限任务被拒绝
T126	实现结果值脱敏策略	P2	M	T024、T117	敏感值按配置保存哈希或脱敏值
T127	实现任务和模型审计	P2	M	T092、T121 至 T123	提交、发布和停用操作可追溯
T128	实现结果保留和清理策略	P2	M	T117	过中间结果可按规则清理

6.6 M28 性能、容量与稳定性

功能范围

- 小表、中表、大表和宽表基准。
- 低错误率和高错误率数据测试。
- 策略数、列数、行数和特征数容量曲线。
- Driver、Executor、内存、磁盘和网络指标。
- 并发数、缓存和分区参数建议。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T129	建立性能基准数据集	P2	M	T066	覆盖规模和错误率维度
T130	建立阶段耗时和资源基线	P2	L	T104 至 T109	输出各阶段耗时和资源占用
T131	完成宽表和 RVD 压力测试	P2	L	T047、T109	列对上限和限流有效
T132	完成大表和恢复测试	P2	L	T107、T114	大表可运行且失败可恢复
T133	输出生产资源建议	P2	M	T130 至 T132	给出分区、并发、缓存和保留建议
T134	输出 P2 生产验收报告	P2	M	T119、T124、T133	FMDB 生产流程达到上线条件

7. P3 功能模块

7.1 M29 历史画像与策略过滤

功能范围

- 保存历史列画像和策略有效性指标。
- 计算新列与历史列的相似度。
- 为新数据集选择更有希望的策略。
- 记录被选择和被过滤策略的原因。
- 对比过滤前后的运行时间和检测质量。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T135	定义历史画像模型	P3	M	T028、T100	可保存列画像和策略效果
T136	实现字段相似度	P3	L	T135	新列可匹配历史相似列
T137	实现策略过滤器	P3	L	T034、T136	可按历史得分选择策略
T138	完成策略过滤对比评测	P3	L	T137、T100	输出耗时和 F1 变化

7.2 M30 KBVD 知识策略

功能范围

- 定义知识库和字典适配接口。
- 支持版本化本地字典或主数据快照。
- 支持字段到知识实体的映射。
- 区分未命中、冲突和外部查询失败。
- 防止外部知识库失败导致全列误报。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T139	定义知识策略接口	P3	M	T033	外部知识源可插拔
T140	实现版本化字典策略	P3	L	T139、T116	字典不命中可生成候选信号
T141	实现知识策略失败隔离	P3	M	T036、T140	外部失败不产生全列误报
T142	完成知识策略评测	P3	M	T140、T141	输出准确性和运行成本

7.3 M31 文本特征增强

功能范围

- 识别适用文本列。
- 生成文本稀疏特征。
- 固化词表、停用词、规范化和特征版本。
- 控制高维特征和内存占用。
- 对比是否提升检测效果。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T143	定义文本列适用规则	P3	S	T027	只有适用列进入文本特征流程
T144	实现文本稀疏特征	P3	L	T054、T143	词表和向量可版本化
T145	实现高维限制和降维配置	P3	M	T144	特征规模受控
T146	完成文本特征对比评测	P3	M	T100、T144	明确效果收益和资源成本

7.4 M32 备选聚类与分类器

功能范围

- Spark 近似聚类实现。
- 决策树和梯度提升分类器。
- 算法参数、随机种子和模型版本管理。
- 与默认层次聚类和逻辑回归进行效果及性能对比。

任务

任务编号	任务	优先级	工作量	前置任务	验收结果
T147	实现 Spark 近似聚类	P3	L	T071、T105	大表聚类可分布式执行
T148	实现决策树分类器	P3	M	T086	可作为列级模型候选
T149	实现梯度提升分类器	P3	L	T086	与 Python demo 集成模型思路对比
T150	完成算法效果和性能对比	P3	L	T100、T147至 T149	给出生产算法选择建议

8. 里程碑计划

8.1 里程碑总表


里程碑	优先级	主要任务	交付目标	退出条件
MS0	P0	T001 至 T010	工程和依赖基线	工程可编译，版本和 MLlib 路径明确
MS1	P0	T011 至 T037	数据、任务、仓储和策略框架	可读取数据并生成可执行策略计划
MS2	P0	T038 至 T070	最小检测闭环	可输出可解释单元格检测结果
MS3	P1	T071 至 T103	Raha 学习闭环	聚类、采样、传播、模型和评测可运行
MS4	P2	T104 至 T114	Spark 并行和恢复	并行任务可限流、幂等和断点续跑
MS5	P2	T115 至 T134	FMDB 生产接入	UDF、权限、性能和生产验收完成
MS6	P3	T135 至 T150	检测增强	历史、知识、文本和备选算法有评测结论

8.2 推荐迭代顺序

以下计划按一个迭代约 10 个工作日组织，不绑定具体人员和自然日期。实际排期应在确认团队规模、FMDB 环境和 MLlib 可用性后调整。

迭代	目标	建议包含任务	可并行工作
迭代 1	工程、依赖、配置和领域对象	T001 至 T015	依赖治理与对象设计可并行
迭代 2	任务编排、数据快照、画像和仓储	T016 至 T032	画像与仓储接口可并行
迭代 3	策略框架、OD 和 PVD	T033 至 T046	OD 与 PVD 可并行
迭代 4	RVD、特征和基础检测	T047 至 T065	RVD 与特征骨架可部分并行
迭代 5	基础对齐测试和聚类采样	T066 至 T078	对齐测试与聚类开发可并行
迭代 6	标签传播、列级模型和版本管理	T079 至 T094	标签传播与模型仓储可并行
迭代 7	Raha 服务和评测闭环	T095 至 T103	训练、采样、检测服务可分工
迭代 8	Spark 并行、检查点和恢复	T104 至 T114	并行执行与恢复机制可并行
迭代 9	FMDB 适配和 UDF	T115 至 T124	读取、写入、模型存储可并行
迭代 10	安全、性能和生产验收	T125 至 T134	安全审计与性能测试可并行
后续迭代	历史和算法增强	T135 至 T150	四个 P3 模块可独立排期

8.3 关键路径





领域对象



数据快照




数据画像



策略计划






```
graph TD; A[ ] --> B[标签传播]; B --> C[列级模型]; C --> D[检测服务]; D --> E[spark生产化]; E --> F[ ]; style A fill:none,stroke:none; style F fill:none,stroke:none;
```

标签传播

列级模型

检测服务

spark生产化



关键路径上的任务不能用临时接口长期占位。尤其是行标识、特征字典、模型版本和结果主键，一旦后期变更会影响全部下游模块。

9. 并行开发建议

9.1 workflow划分

workflow	主要模块	可以开始的条件
工程与平台流	M01、M04、M07、M14	项目启动即可开始
数据与画像流	M03、M05、M06	核心对象初版完成
策略与特征流	M08 至 M12	画像接口和策略接口稳定
学习算法流	M16 至 M22	特征对象和字典稳定
Spark 生产化流	M23、M24、M28	Raha 服务流程稳定
FMDB 接入流	M25 至 M27	仓储和服务接口稳定
增强流	M29 至 M32	评测服务和生产基线完成

9.2 接口先行要求

以下接口应在实现前先完成详细设计和评审：

- `RahaDatasetLoader`。
- `DetectionStrategy`。
- `FeatureAssembler`。
- `ColumnClusterer`。
- `LabelRepository`。
- `ModelTrainer` 和 `ModelPredictor`。
- `ModelRepository`。
- `FmdbDatasetLoader` 和 `FmdbResultWriter`。
- 三个表级 UDF 的请求和返回结构。

接口评审通过后，不应在没有兼容方案的情况下频繁修改字段语义。

10. 工作量标识

任务表中的工作量是相对估算，不代表最终人日承诺：

标识	参考范围	说明
S	1 至 2 人日	单一对象、单一配置或小范围测试
M	3 至 5 人日	一个完整功能点及对应测试
L	6 至 10 人日	跨对象、Spark 计算或复杂集成任务

以下情况需要重新估算：

- FMDB 接口资料和运行环境不完整。
- MLlib 需要额外补包或处理复杂冲突。
- 行标识无法由输入表稳定提供。
- 聚类算法需要从零实现分布式版本。
- 人工标注需要新建前端或外部系统。
- 知识库需要实时远程调用而非本地快照。

11. 全局完成标准

每个任务只有同时满足以下条件才可以标记完成：

1. 代码实现符合模块边界，没有引入数据纠正逻辑。
2. 新增和修改注释使用中文简体。
3. 关键路径、外部调用和异常处理具备日志。
4. 核心对象、私有变量和关键方法具备用途和边界说明。
5. 单元测试覆盖正常、边界和异常场景。
6. 文件编码为 UTF-8 无 BOM，换行使用 LF。
7. 检测输出能够追溯任务、快照、策略、特征和模型版本。
8. 对输入表没有更新、覆盖和清洗回写操作。
9. 任务相关文档同步更新。
10. 依赖没有引入 Spark 4 `2.13` 或同组件多版本冲突。

12. 阶段验收门槛

12.1 P0 验收门槛

- 一张固定测试表可以通过 Spark 本地模式完成检测。
- OD、PVD、RVD 均有可运行策略。
- 每个单元格可以生成策略特征。
- 基础检测结果包含定位、分数、策略命中和原因。
- 同一任务重跑不会生成重复有效结果。
- 结果没有修复值字段和清洗回写行为。

12.2 P1 验收门槛

- 支持列内聚类 and 基于聚类覆盖的元组采样。
- 支持直接标签、同质性传播和多数传播。
- 支持每列训练模型和批量预测。
- 模型、特征字典、策略计划和模式哈希相互绑定。
- 能输出单元格级精确率、召回率和 F1。
- 与 Python demo 的主要行为差异有书面说明。

12.3 P2 验收门槛

- 策略、列和分区任务可以并行执行并受限流控制。
- 阶段失败后可以从检查点恢复。
- FMDB 环境中能够读取输入并写入检测结果。
- 三个表级 UDF 完成参数、异常和权限测试。
- 大表和宽表有性能基线和生产资源建议。
- 日志、指标、脱敏和审计达到生产要求。

12.4 P3 验收门槛

- 每个增强模块都有独立开关和版本。
- 增强能力关闭时不影响生产主流程。
- 每项增强都有检测质量、运行时间和资源成本对比。
- 只有有明确收益的增强能力才进入默认配置。

13. 启动前必须确认的决策

以下决策建议在 MS0 结束前确认：

决策编号	决策事项	影响模块	未确认时的临时方案
D01	MLlib 3.3.1 2.12 是否可用	M19、M32	使用规则加权完成 P0
D02	输入表稳定行标识来源	M05 及全部下游	测试环境使用显式测试主键
D03	中间结果存储位置	M07、M24、M25	开发期使用文件或测试仓储
D04	模型文件存储位置	M20、M25	开发期使用本地版本目录
D05	FMDB jar 唯一版本组合	M25、M26	P0 使用核心 Spark 依赖开发
D06	UDF 同步或异步语义	M26	推荐异步返回 jobId
D07	人工标注承载系统	M17、M18	先使用标注任务表和评测真值
D08	首期聚类算法	M16	小表使用层次聚类

14. 推荐立即启动的任务

项目启动后，第一批建议立即执行以下任务：

1. T001 创建 Maven 工程和包目录。
2. T002 固定 JDK、Spark 和 Scala 版本。
3. T003 建立本地 jar 白名单。
4. T004 确认 MLlib 可用性。
5. T006 至 T010 完成配置对象和校验。
6. T011 至 T015 完成核心领域对象。
7. T066 提前准备固定测试数据集。
8. T067 提前生成 Python demo 基线输出。

其中 T003、T004、T066 和 T067 可以与工程骨架并行，尽早暴露依赖和算法对齐风险。

15. 计划结论

本任务计划建议严格按照以下主线推进：

工程基础

- > 数据快照和画像
- > 基础检测策略
- > 单元格特征
- > 最小检测闭环
- > 聚类和采样
- > 标签传播
- > 列级模型
- > Spark 并行和恢复
- > FMDB 与 UDF 接入
- > 历史和知识增强

P0 和 P1 决定 Raha 检测能力是否成立，必须优先保证语义正确和行为可验证；P2 负责把正确的检测流程变成可上线、可恢复和可观测的生产系统；P3 只在主流程稳定后按评测收益逐项引入。

任何阶段都不得通过加入纠正候选、修复值或清洗回写来扩展任务范围。需要数据纠正时，应另行建立独立工程、接口、模型和审计边界。

16. 迭代执行状态

迭代	任务范围	状态	完成时间	验收记录
迭代 1	T001 至 T015	已完成	2026-07-14	Raha数据检测迭代1落地与测试报告-202607141943.md
迭代 2	T016 至 T032	已完成	2026-07-14	Raha数据检测迭代2落地与测试报告-202607142038.md
迭代 3	T033 至 T046	已完成	2026-07-14	Raha数据检测迭代3落地与测试报告-202607142123.md
迭代 4	T047 至 T065	已完成	2026-07-14	Raha数据检测迭代4落地与测试报告-202607142213.md
迭代 5	T066 至 T078	已完成	2026-07-14	Raha数据检测迭代5落地与P0验收报告-202607142318.md
迭代 6	T079 至 T094	已完成	2026-07-15	Raha数据检测迭代6落地与P1验收报告-202607150010.md
迭代 7	T095 至 T103	已完成	2026-07-15	../20260715/Raha数据检测迭代7落地与P1验收报告-202607150727.md
迭代 8	T104 至 T114	已完成	2026-07-15	../20260715/Raha数据检测迭代8落地与P2阶段验收报告-202607151008.md
迭代 9	T115 至 T124	未开始	-	-
迭代 10	T125 至 T134	未开始	-	-

迭代 1 已统一使用根包 `com.fiberhome.ml.raha`。JDK 8 完整构建、Java 8 API 检查、依赖禁止规则、单元测试、jar 打包、字节码版本和文件编码检查均已通过。

迭代 2 已完成任务编排、文件数据读取、快照绑定、列画像、值保护和统一内存仓储。T016 至 T032 逐项核对通过，Spark 本地端到端链路和 38 个测试全部成功，具体记录见 `Raha数据检测迭代2落地与测试报告-202607142038.md`。

迭代 3 已完成统一策略契约、确定性策略计划、超时失败隔离、运行摘要、OD 和 PVD 候选检测。

T033 至 T046 逐项核对通过，Spark 端到端策略链路和 56 个测试全部成功，具体记录见 [Raha数据检测迭代3落地与测试报告-202607142123.md](#)。

迭代 4 已完成 RVD 有向列对与一对多冲突检测、策略和上下文特征、稳定字典、稀疏持久化、规则加权检测、结果解释、检测结果持久化，以及日志、指标、异常和敏感值保护。T047 至 T065 逐项核对通过，Spark 端到端检测链路和 69 个测试全部成功，具体记录见 [Raha数据检测迭代4落地与测试报告-202607142213.md](#)。

迭代 5 已完成固定脏表和真值表、实际 Python demo 基线、P0 检测验收、可替换层次聚类、聚类版本和成员持久化、聚类覆盖采样、标注任务状态和评测真值自动标注。T066 至 T078 逐项核对通过，Spark 端到端评测链路和 81 个测试全部成功，具体记录见 [Raha数据检测迭代5落地与P0验收报告-202607142318.md](#)。

迭代 6 已完成标签仓储、同质性和多数传播、传播冲突与权重、列级训练数据、类别和样本权重、Spark MLlib 逻辑回归、规则加权降级、列级预测、不可训练列处理、模型元数据和文件、发布状态机、兼容校验及历史发布模型回滚。T079 至 T094 逐项核对通过，真实本地 Spark MLlib 训练和 94 个全量测试全部成功，具体记录见 [Raha数据检测迭代6落地与P1验收报告-202607150010.md](#)。

迭代 7 已完成训练、采样和已发布模型检测服务，统一任务结果，全量真值差异，单元格级精确率、召回率、F1 和平均精确率，候选阈值比较与模型元数据写回，以及 Raha 学习流程端到端对齐。T095 至 T103 逐项核对通过，99 个全量测试全部成功，具体记录见 [../20260715/Raha数据检测迭代7落地与P1验收报告-202607150727.md](#)。

迭代 8 已完成策略级并行，列级特征、聚类、训练和预测并行，Spark 分区预测，广播与缓存大小控制，并发和超时限流，阶段检查点、严格版本复用、失败重试审计，以及仅重跑失败策略的部分恢复。T104 至 T114 逐项核对通过，110 个全量测试、Java 8 API 检查和 jar 打包全部成功，具体记录见 [../20260715/Raha数据检测迭代8落地与P2阶段验收报告-202607151008.md](#)。