

Raha 工程源码完整分析

1. 分析范围与结论

本文分析对象为 `F:/ai-code/fmdb_udf_raha` 当前工作区，重点覆盖 `src/main`、`src/test`、`pom.xml`、`README.md`、默认配置和容器验收入口。

文档首次生成于 2026-07-15 09:43，本次于 2026-07-17 10:20 基于提交 `86f1fc9` 及其后的当前工作区重新分析。与上一版文档对应的源码快照相比，工程从“包含部分生产治理能力的组件”收缩为“Raha 核心算法、FMDB 适配和集群验证组件”。

当前源码规模如下：

项目	当前数量	上一版数量	变化
主代码 Java 文件	279	324	-45
主代码行数	23536	25735	-2199
测试 Java 文件	49	56	-7
测试代码行数	7213	7975	-762
测试方法	136	154	-18
主代码包	27	32	-5

当前工程的核心能力为：

- 从 CSV、JSON、Parquet、FMDB 表或只读 SQL 加载数据并生成稳定快照。
- 生成字段空值、频率、长度、数值分布和字符类型画像。
- 生成并执行 OD、PVD、RVD 三类弱监督检测策略。
- 将策略命中与上下文信号组装为版本化稀疏特征。
- 对单列样本执行精确或可扩展聚类，并按聚类覆盖度逐轮主动采样。
- 合并直接标签和聚类传播标签，构建列级训练数据。
- 使用 Spark MLlib 逻辑回归或规则加权模型完成训练与检测。
- 通过质量门禁管理候选模型，并支持发布、停用和回滚。
- 使用独立验证坐标选择阈值，使用最终测试坐标计算检测指标。
- 通过统一仓储契约保存任务、阶段、标签、策略、特征和模型元数据。
- 通过 FMDB 适配器加载数据、保存模型和写入任务及检测结果。
- 提供训练、检测、采样三个 Spark SQL 异步表级 UDF。
- 提供带租约的共享目录工作器和可执行容器黑盒验收入口。

本次最重要的边界变化如下：

- `security`、`audit`、`retention`、`performance`、`production` 五个包已经整体删除。
- 权限、专用审计、自动过期清理、内置压测、容量建议和生产就绪门禁不再由本工程提供。
- 特征和 FMDB 检测结果标准落库链路固定只保留值哈希，`masked_value` 兼容字段固定写空。
- UDF 的 `caller` 只用于追踪和日志，不再参与授权。
- 上述治理责任必须由 FMDB 宿主、上游平台或发布流程承担，当前版本不能直接按生产安全版本交付。

一句话概括：当前工程是具备完整 Raha 学习闭环、FMDB 接入、异步 UDF 和容器验收能力的验证组件，不是自带生产治理的常驻服务。

2. 技术基线与交付形态

项目	当前配置
Java	JDK 8, Maven Enforcer 限制为 [1.8,1.9)
Maven	3.8 及以上
Spark	3.3.1
Scala 二进制版本	2.12
Spark SQL	provided
Spark MLlib	provided
日志	SLF4J 1.7.36, provided
测试	JUnit Jupiter 5.10.2
交付	普通 Jar 和 a11 分类的 Shade Jar
编码	UTF-8, 无 BOM, LF


Spark SQL、Spark MLlib 和 SLF4J 由 FMDB 运行环境提供，不会打入完整 Jar。构建通过 Animal Sniffer 检查 Java 8 API 兼容性。

工程同时具有三种交付入口：

入口	主要类	定位
Spark SQL UDF	F_DW_RAHA TRAIN、F_DW_RAHA DETECT、F_DW_RAHA SAMPLE	异步校验、幂等建单和结果定位
Java 服务	Raha TrainService、Raha DetectService、Raha SampleService	宿主组装后的核心用例入口
容器验收应用	Raha ContainerValidationApplication	Spark 和文件队列全链路黑盒验证

容器验收类具有 main 方法，但它不是通用生产启动器。工程没有依赖注入容器、长期运行的统一调度器或完整 FMDB 安装脚本。

3. 总体架构



架构划分如下：

层次	包	职责
验收应用层	<code>app</code>	运行本地、工作器和组合模式的黑盒验收
平台入口层	<code>udf</code>	注册函数、解析请求、幂等建单和文件任务消费
用例编排层	<code>service</code> 、 <code>job</code> 、 <code>job.stage</code>	训练、采样、检测和通用阶段控制
算法层	<code>strategy</code> 、 <code>feature</code> 、 <code>cluster</code> 、 <code>sampling</code> 、 <code>label</code> 、 <code>model</code> 、 <code>detection</code> 、 <code>evaluation</code>	完成 Raha 核心闭环
数据接入层	<code>data.loader</code> 、 <code>data.profile</code> 、 <code>fmdb</code>	加载文件或平台数据，生成画像并写入产物
领域层	<code>data</code> 、 <code>checkpoint</code>	定义数据集、坐标、状态、快照和检查点
基础设施层	<code>repository</code> 、 <code>parallel</code> 、 <code>observability</code> 、 <code>error</code>	持久化、并发、日志上下文和统一异常
公共工具层	<code>config</code> 、 <code>util</code>	配置、哈希、表单编解码和通用校验

4. 包结构与职责

当前 27 个主代码包及文件数如下，合计 279 个 Java 文件：

包	文件数	主要职责
com.fiberhome.ml.raha.app	1	容器黑盒验收
com.fiberhome.ml.raha.checkpoint	6	阶段检查点执行与复用
com.fiberhome.ml.raha.cluster	11	精确和可扩展列聚类
com.fiberhome.ml.raha.config	19	算法、资源和 UDF 配置
com.fiberhome.ml.raha.data	17	核心领域对象与状态
com.fiberhome.ml.raha.data.loader	12	文件加载、行标识和快照
com.fiberhome.ml.raha.data.profile	2	列画像计算与保存
com.fiberhome.ml.raha.detection	9	规则评分、解释和指标
com.fiberhome.ml.raha.error	3	统一错误分类与异常
com.fiberhome.ml.raha.evaluation	11	真值差异、切分、阈值和评测
com.fiberhome.ml.raha.feature	8	特征字典和稀疏特征
com.fiberhome.ml.raha.fmdb	9	FMDB 加载、模型和结果适配
com.fiberhome.ml.raha.job	13	任务状态机和阶段编排
com.fiberhome.ml.raha.job.stage	10	十类阶段处理器
com.fiberhome.ml.raha.label	10	真值适配和标签传播
com.fiberhome.ml.raha.model	25	训练、预测、质量和模型生命周期
com.fiberhome.ml.raha.observability	2	日志上下文和敏感日志保护
com.fiberhome.ml.raha.parallel	5	受控并发、超时和 Spark 资源管理
com.fiberhome.ml.raha.repository	31	统一仓储契约和内存实现
com.fiberhome.ml.raha.sampling	9	聚类覆盖采样和标注任务
com.fiberhome.ml.raha.service	19	训练、检测、采样和主动学习入口
com.fiberhome.ml.raha.strategy	20	策略计划、注册和批量执行

包	文件数	主要职责
<code>com.fiberhome.ml.raha.strategy.od</code>	3	离群检测策略
<code>com.fiberhome.ml.raha.strategy.pvd</code>	4	模式违规策略
<code>com.fiberhome.ml.raha.strategy.rvd</code>	1	关系违规策略
<code>com.fiberhome.ml.raha.udf</code>	16	Spark SQL UDF 和文件任务工作器
<code>com.fiberhome.ml.raha.util</code>	3	哈希、表单和通用值校验

4.1 service

该包提供完整用例入口，而不是简单的算法工具集合。

关键类	职责
<code>RahaFeaturePreparationService</code>	生成策略计划、批量执行策略并组装特征
<code>ActiveSamplingOrchestrator</code>	按一轮一个元组执行主动采样并累计直接标签
<code>RahaSampleService</code>	复用或生成聚类，创建和完成标注任务
<code>RahaTrainService</code>	编排特征、聚类、传播、并行列训练和候选模型
<code>RahaDetectService</code>	加载已发布模型并按字段检测，汇总部分成功状态
<code>RahaFeaturePreparationResult</code>	保存策略、特征及可选聚类，并支持释放命中对象

训练服务可以接收采样阶段已经准备的特征和聚类。未提供聚类时才重新计算；容器验收链路当前会显式复用主动采样聚类。

4.2 job 与 job.stage

`job` 定义 `RahaJob`、`RahaStage`、状态转换、幂等键、失败决策和阶段上下文。

`RahaJobOrchestrator` 按顺序执行阶段处理器，并根据可恢复性、失败比例和重试次数决定继续、重试或终止。

`job.stage` 保存数据加载、画像、策略计划、策略执行、特征、聚类、采样、真值标签和检测等十个处理器。`StageType` 还定义传播、训练、评测和最终持久化语义，但当前没有全部对应的阶段处理器；完整学习闭环主要由 `service` 包编排。

4.3 config

配置包聚合 `StrategyConfig`、`FeatureConfig`、`ModelConfig`、`ClusteringConfig`、`SamplingConfig`、`ResourceConfig`、`FailureToleranceConfig` 和 `UdfConfig`。

`RahaConfigLoader` 按内置属性、外部 UTF-8 文件、系统属性的顺序覆盖，并拒绝默认配置未声明的键。

`RahaConfigFactory` 当前只负责算法、资源、失败容忍和 UDF 配置，不再生成安全、保留、性能或生产资源对象。`RahaJobConfig` 已删除结果保留天数，配置指纹也不再包含该字段。

4.4 data、data.loader 与 data.profile

`data` 提供不可变 `RahaDataset`、`DatasetSnapshot`、`ColumnMetadata`、`ColumnProfile`、`CellCoordinate`、`CellValue`、`DetectionResult` 及任务、阶段、策略和模型状态枚举。

`data.loader` 使用 `DataLoadRequest` 描述输入，支持 CSV、JSON、Parquet、FMDDB 表和 FMDDB SQL。`FileRahaDatasetLoader` 处理文件来源；`FmdDbDatasetLoader` 处理平台来源。

`RowIdValidator` 强制行标识存在、非空且唯一，`SchemaHasher` 和 `SnapshotMetadataFactory` 生成稳定模式及快照标识。

`data.profile` 计算总数、空值、空白、不同值、长度、数值统计、四分位数、字符类型和高频值哈希，为策略计划提供依据。

4.5 strategy、strategy.od、strategy.pvd 与 strategy.rvd

`StrategyPlanGenerator` 根据画像、字段范围和配置生成确定性计划；`StrategyRegistry` 保存可执行策略；`StrategyExecutionService` 负责并发、超时、失败隔离和批次汇总。

策略族	当前实现	作用
OD	低频值、数值距离、四分位异常	发现低频值和数值离群
PVD	字符集、长度、空值占位、类型格式	发现列内模式违规
RVD	一对多关系冲突	发现列间函数依赖冲突

RVD 计划不再一次性全部执行。`RvdBatchStrategyExecutor` 默认每 16 个计划形成一个 Spark 子批，各子批共享长表、关联和聚合逻辑；总超时在全部子批之间共享。单个子批失败只影响该子批，剩余子批继续执行；总预算耗尽时剩余计划统一标记超时。数字 16 当前为代码常量，不是外部配置。

4.6 feature

`FeatureAssembler` 将策略命中和稀有值、关系冲突、空值、空白、混合类型等上下文信号转换为 `SparseFeatureRow`。`FeatureDictionary` 固定特征顺序，`FeatureDictionaryVersioner` 生成稳定版本，常量特征可以删除。

标准组装链路只保留 `valueHash`，`maskedValue` 固定为 `null`。这表示工程不再提供可配置的展示值脱敏策略；领域对象保留该字段仅用于兼容现有结构。

4.7 cluster、sampling 与 label

`HierarchicalColumnClusterer` 适合不超过配置样本上限的小样本精确聚类；

`ScalableColumnClusterer` 对大样本使用确定性余弦分区。`ColumnClusteringService` 按字段并行执行并保存结果。

`SamplingService` 根据聚类覆盖度生成元组级标注任务。`ActiveSamplingOrchestrator` 将总预算拆成多轮，每轮只选一个元组；它从特征坐标提取候选行，并排除已经存在非传播直接标签的整行。有效预算为请求预算与剩余候选行数的较小值，没有候选行时失败。

`LabelPropagationService` 在同一聚类内传播标签，保留直接标签优先级、冲突聚类和未标注聚类统计。训练样本不可用时，训练服务可回退到仅直接标签的数据集，但单一类别仍会导致该列跳过训练。

4.8 model

该包完成列级训练数据构建、Spark MLlib 逻辑回归、规则加权降级、模型文件保存、模型兼容检查、预测和生命周期管理。

`ModelQualityGate` 检查评分标准差、预测正例比例和最低 F1。`ModelReleaseManager` 保留候选、发布、停用和回滚，并拒绝发布质量门禁未通过的候选；它已经删除调用方、权限检查和专用审计依赖。

`PublishedColumnModelLoader` 校验数据集、字段、模式哈希、特征字典和策略计划版本。当前 `RahaDetectService` 使用 `ColumnModelPredictor` 的 Java 列表路径；
`PartitionedColumnModelPredictor` 已实现但尚未成为默认检测路径。

4.9 detection 与 evaluation

`detection` 提供基础规则评分、权重评分、检测解释、字段诊断和指标对象。模型预测结果保存错误标志、分数、阈值、原因、策略标识及版本信息。

`evaluation` 负责脏数据与干净数据的真值差异、检测指标、阈值候选比较以及评测坐标切分。
`EvaluationSplitService` 先排除训练直接标签坐标，再按稳定哈希划分阈值验证集与最终测试集；至少需要两个非训练坐标。极小数据集全部落入同一侧时，会按 `cellId` 稳定顺序移动一个坐标，保证两侧均非空。

4.10 repository 与 checkpoint

`repository` 定义任务、阶段、检查点、画像、策略、特征、标签、聚类、模型和检测结果等仓储接口。所有 `Default...Repository` 仍建立在统一 `RahaRepository` 之上，当前只提供 `InMemoryRahaRepository` 进程内实现。

内存仓储已对单条记录保存和事务回调增加同步控制，但不提供跨进程共享持久化。FMDB 模型表和结果表适配器是另一套平台持久化机制，不等价于统一仓储的 FMDB 实现。

`checkpoint` 提供严格版本匹配、历史成功复用、输入变化重算和失败重试。
`StageCheckpointRunner` 尚未接入 `RahaJobOrchestrator`，因此通用任务流水线不会自动跳过历史成功阶段。

4.11 parallel、observability 与 error

`BoundedParallelExecutor` 对策略和列任务提供固定并发、超时、异常归档和稳定结果顺序。
`SparkResourceManager` 管理广播和缓存资源释放。并行失败会进入任务摘要，允许训练或检测返回部分成功。

`RahaLogContext` 统一保存任务、阶段、数据集和快照上下文，`SensitiveLogGuard` 避免原始值进入日志。`error` 包提供稳定错误码、分类和统一运行时异常。

4.12 fmdb

`FmdbDatasetLoader` 读取目录表或只读 SQL；SQL 只接受以 `SELECT` 或 `WITH` 开头的语句。
`FmdbModelStore` 保存模型参数和特征字典。`SparkSqlFmdbResultWriter` 写入任务及检测结果，并在写入前按业务键过滤已有记录。

`FmdbTableGateway` 仍保留按时间删除的底层原语，但当前主代码没有保留规则或清理服务调用它，因此不能视为已提供自动保留清理。

`InMemoryFmdbTableGateway` 在幂等追加后立即执行本地检查点并释放旧数据集，以截断连续追加造成的 Spark 血缘；这是验收网关优化，不代表生产 `SparkSqlFmdbTableGateway` 具有分布式事务。

4.13 udf

三个 UDF 接收 URL 表单编码字符串并返回 JSON 文本。`RahaUdfRequestParser` 拒绝未知键、重复键、非法表名、非只读 SQL、任务参数串用和超长请求。

`RepositoryBackedRahaUdfJobSubmitter` 当前只执行请求校验、配置摘要、幂等冲突检查、核心任务保存和 FMDB 任务状态写入，不再执行权限或审计。`RahaUdfRuntime` 保存进程级提交器，`RahaUdfRegistrar` 完成三个函数的注册和失败清理。


`FileRahaUdfJobworker` 使用 `request`、`running`、`completed`、`failed` 和 `lease` 文件表达状态，通过原子移动认领任务；启动时可恢复租约缺失或过期的运行中任务。它提供单次扫描能力，不是自带守护循环的生产消费者。

4.14 app 与 util

`RahaContainerValidationApplication` 支持组合模式和分离的提交、消费模式，串联 UDF、文件工作器、主动采样、训练、模型发布、阈值选择、检测、评测和策略对齐产物输出。

容器链路会在采样后复用聚类，写出策略对齐文件后删除仓储中的策略命中并释放内存对象，再进入训练。`util` 当前只保留 `HashUtils`、`FormDataCodec` 和 `ValueUtils`；原值保护工具已经删除。

5. 主依赖与数据关系



核心依赖方向为入口依赖编排、编排依赖算法与仓储、算法依赖领域对象。算法包不依赖 UDF 或容器应用，便于宿主替换入口和持久化实现。

工程同时存在两类持久化关系：

类型	组件	当前边界
核心统一仓储	<code>RahaRepository</code> 及各领域仓储	只有进程内实现，适合测试和单进程验证
FMDB 平台适配	<code>FmdbTableGateway</code> 、 <code>FmdbModelStore</code> 、 <code>FmdbResultwriter</code>	保存平台任务、模型、字典和检测结果

两者没有统一事务。任务仓储保存成功后 FMDB 写入失败，或文件队列状态变化后业务仓储失败，都可能产生跨介质不一致。

6. 配置体系

配置优先级从低到高为：


- 1. 类路径 `raha-defaults.properties`。
- 2. `RAHA_CONFIG_FILE` 或 `raha.config.file` 指定的 UTF-8 属性文件。
- 3. JVM 中以 `raha.` 开头的系统属性。

当前默认配置包含 81 个算法、模型、资源、失败容忍和 UDF 键。关键默认值如下：

配置项	默认值	说明
<code>raha.strategy.families</code>	<code>OD, PVD, RVD</code>	默认策略族
<code>raha.strategy.max-count</code>	<code>1000</code>	最大策略数
<code>raha.strategy.max-rvd-column-pairs</code>	<code>500</code>	最大关系列对数
<code>raha.model.classifier-type</code>	<code>LOGISTIC_REGRESSION</code>	默认分类器
<code>raha.model.fallback-enabled</code>	<code>false</code>	默认禁止规则静默降级
<code>raha.model.quality-gate.enabled</code>	<code>true</code>	启用模型质量门禁
<code>raha.sampling.labeling-budget</code>	<code>20</code>	主动标注预算
<code>raha.clustering.max-sample-count</code>	<code>500</code>	精确聚类样本上限
<code>raha.resource.max-parallel-strategies</code>	<code>4</code>	策略并发上限
<code>raha.resource.max-parallel-columns</code>	<code>4</code>	字段并发上限
<code>raha.failure.max-retry-count</code>	<code>1</code>	阶段最大重试次数
<code>raha.udf.max-request-length</code>	<code>65536</code>	UDF 请求最大字符数

旧外部配置必须删除 `raha.security.*`、`raha.retention.*`、`raha.performance.*` 和 `raha.job.result-retention-days`。配置加载器会把这些旧键视为未知配置并在组装阶段失败。


7. 通用任务与 UDF 流程



UDF 返回 `ACCEPTED` 只表示请求通过校验并成功建单，不表示算法已经完成。相同数据集和幂等键若任务类型或规范配置不同，会返回幂等冲突。

文件工作器通过租约和原子移动降低多进程重复消费风险，但共享目录语义仍取决于底层文件系统。宿主主要负责轮询、进程保活、失败告警、任务重放和最终结果查询。

通用 RahaJobOrchestrator 的阶段失败处理如下：



8. 主动采样与训练闭环

生成策略计划

```
graph TD; A[ ] --> B[执行策略]; B --> C[组装特征]; C --> D[列内聚类]; D --> E[ ]; style A fill:none,stroke:none; style E fill:none,stroke:none;
```

执行策略

组装特征

列内聚类

计算有效预算


```
graph TD; A[ ] --> B[逐轮选取元组]; B --> C[获取直接标签]; C --> D[标签传播]; D --> E[构建列训练集]; E --> F[ ]; style A fill:none,stroke:none; style F fill:none,stroke:none;
```

逐轮选取元组

获取直接标签

标签传播

构建列训练集




关键语义如下：

- 主动采样按行选择任务，但标签和评测坐标按单元格表达。
- 一行存在任何非传播直接标签时，该整行不会再次进入主动采样候选。
- 请求预算超过剩余候选行时自动收缩；没有候选时直接失败。
- 聚类结果可由采样传给训练复用，通用调用方未提供时训练服务自行计算。
- 容器链路在策略对齐产物写出后释放策略命中，`getHitCount` 仍从摘要返回原始数量，但 `getHits` 不再含已释放对象。

- 每列独立构建训练集和训练模型，缺少特征、缺少标签、标签冲突或单一类别时可以跳过该列。
- 部分列失败或跳过时，训练任务可返回部分成功，而不是强制整表失败。

9. 发布、阈值、检测与评测



划分评测坐标



验证集选阈值




保存新阈值



加载发布模型





同一数据集和字段只允许一个当前发布模型。发布新版本时旧版本转为停用；回滚只允许恢复曾发布过的历史版本。权限和专用审计已从模型生命周期中删除。

阈值选择和独立评测切分目前由容器验收入口显式编排，不是 `RahaTrainService` 的通用内建步骤。调用高层训练服务的宿主必须自行决定何时发布、如何准备独立真值以及是否调整阈值。

生产检测只加载已发布且版本兼容的模型。当前列表预测路径会将每列稀疏特征收集到 Driver；大规模数据应接入已存在的分区预测器或提供新的分布式实现。

10. 确定性、数据保护与可观测性

10.1 确定性

- 模式哈希、快照标识、配置指纹、策略标识、字典版本和模型版本均使用规范化文本及稳定哈希。
- 策略、字段、特征、聚类 and 并行结果按稳定顺序输出。
- 聚类、采样和训练使用显式随机种子。
- 评测切分使用盐值与单元格标识的稳定哈希，极小集合重平衡也使用稳定顺序。
- 幂等键同时校验任务类型和规范配置，避免同键异义。

10.2 数据保护

- 策略命中、稀疏特征和检测结果以值哈希关联，不应记录原始单元格值。
- 标准特征组装和 FMDB 结果写入固定将 `masked_value` 写空。
- 日志保护类用于检查敏感上下文，异常摘要避免回显完整请求。
- 工程已无应用内权限判断、数据集访问隔离、结果读取审计或可配置脱敏展示。
- 实际访问安全必须由 FMDB 账户、表权限、网络隔离、传输安全和宿主鉴权共同保证。

10.3 日志与指标

外部文件、Spark 和 FMDB 调用，核心任务开始、关键分支、结束及异常捕获均使用 SLF4J 记录上下文和异常堆栈。任务摘要、策略摘要、聚类指标、传播指标和检测字段诊断可用于问题定位。

工程不再包含阶段资源探针、容量档位和生产门禁，因此这些业务日志不能替代 Spark 指标、FMDB 监控或独立容量测试。

11. 2026-07-16 至 2026-07-17 变更分析

11.1 删除治理能力

删除范围	文件数	当前影响
<code>security</code>	13	无应用内权限、隔离和结果访问保护
<code>audit</code>	8	无专用审计事件及 FMDB 审计表写入
<code>retention</code>	3	无规则化自动清理
<code>performance</code>	17	无内置基准、阶段探针、容量建议
<code>production</code>	3	无生产就绪检查
<code>ValueProtectionUtils</code>	1	无可配置掩码算法

核心算法没有依赖这些包，OD、PVD、RVD、特征、聚类、采样、传播、训练、检测、评测和 UDF 建单仍然保留。代价是当前版本只能用于隔离验证环境，或由宿主完整补齐治理边界。

11.2 主动学习与评测修正

- 主动采样预算按剩余未标注候选行收缩，避免小数据集重复选行或预算不可达。
- 容器验收还会预留至少一行用于评测，避免所有行都进入直接标签。
- 评测切分要求至少两个非训练坐标，并在单侧为空时稳定重平衡。

11.3 内存与聚类复用

- `RahaFeaturePreparationResult` 新增可选聚类结果及 `withClustering`、`withoutStrategyHits`。
- 容器采样后将聚类传给训练，避免重复聚类。
- 策略对齐产物生成后删除仓储策略命中并释放对象，只保留摘要计数。

- 内存 FMDB 网关追加后截断 Spark 血缘，降低长期验证中的递归重算和内存压力。

11.4 RVD 分批执行

- 默认每 16 个 RVD 计划形成一个子批。
- 每个子批单独设置 Spark 作业组，超时可取消当前作业。
- 全部子批共享总超时，失败半径由全部计划缩小到单个子批。
- 子批末端仍使用 `collectAsList`，只是限制瞬时规模，没有彻底消除 Driver 压力。

11.5 破坏性兼容变化

以下类型已删除旧治理参数或重载，直接依赖旧接口的宿主需要重新编译和修改装配：

- `RahaJobConfig`
- `RahaConfigFactory`
- `FeatureAssembler`
- `SparkSqlFmdbResultWriter`
- `ModelReleaseManager`
- `RepositoryBackedRahaUdfJobSubmitter`

当前工作区还扩充了 `RahaUdfRequestParser.ALLOWED_KEYS` 的中文源码说明，逐项记录八个通用字段和三个任务专属字段的必填性、用途与样例。该变化只增强源码可读性，没有修改字段白名单、解析规则或 UDF 运行契约。

12. 测试覆盖与本次验证

当前 49 个测试类覆盖 136 个测试方法，主要范围如下：

范围	代表测试
配置和领域对象	<code>RahaConfigLoaderTest</code> 、 <code>DomainObjectTest</code>
文件与 FMDB 加载	<code>FileRahaDatasetLoaderIntegrationTest</code> 、 <code>FmdbAdapterIntegrationTest</code>
画像和策略	<code>ColumnProfilerIntegrationTest</code> 、OD、PVD、RVD 集成测试
特征和聚类	<code>FeatureAssemblerIntegrationTest</code> 、两个列聚类测试
主动采样和传播	<code>ActiveSamplingOrchestratorTest</code> 、 <code>SamplingServiceTest</code> 、 <code>LabelPropagationServiceTest</code>
训练和模型	<code>ColumnModelTrainerIntegrationTest</code> 、 <code>ModelLifecycleIntegrationTest</code>
检测和评测	<code>BasicDetectionServiceTest</code> 、评测与阈值测试
任务和检查点	<code>RahaJobOrchestratorTest</code> 、 <code>StageCheckpointRunnerTest</code>
并行恢复	<code>BoundedParallelExecutorTest</code> 、策略并行恢复测试
UDF 和文件工作器	三类 UDF、配置和工作器测试
Python 对齐	<code>PythonBaselineArtifactTest</code>

本次在 JDK 8u492 和 Maven 3.9.12 环境执行 `mvn -q clean test`，Surefire 汇总为 136 项测试全部通过，0 失败、0 错误、0 跳过。测试日志中出现的模拟阶段失败、聚类失败和非法 UDF 请求异常均为故障隔离测试的预期分支。随后执行 `mvn -q -DskipTests verify`，编译、打包和 Java 8 API 兼容性检查均通过。当前工作区扩充请求字段说明后，又定向执行 `RahaTableUdfIntegrationTest` 和 `RahaUdfConfigurationTest`，6 项测试全部通过。

13. 当前实现边界与风险

13.1 平台接入

- `RahaRepository` 只有内存实现，生产共享仓储需要宿主补充。
- FMDB 写入的读取、过滤、追加不是集群级原子事务，跨进程强幂等依赖平台约束。
- UDF 只建单，后台工作器只有单次扫描方法，宿主必须提供持续调度和故障告警。
- 核心仓储、FMDB 表和文件队列之间没有统一事务。

13.2 算法与规模

- 多个 OD、PVD 和 RVD 实现仍在边界调用 `collectAsList`。
- 默认检测路径仍按 Java 列表预测，宽表和大数据量存在 Driver 内存压力。
- 精确层次聚类只适合小样本，大样本近似聚类需要继续用真实数据验证效果。
- RVD 子批大小硬编码为 16，不能按目标集群动态调整。
- `KBVD` 和 `TFIDF` 只有策略族语义，没有具体策略实现。
- `DECISION_TREE` 和 `GBT` 未接入训练器。

13.3 主动学习与评测

- 每轮同步调用标签提供器，尚无标注事务、并发编辑或撤销机制。
- 一行有任意直接标签就排除整行，这是当前固定采样语义，可能降低部分标注场景的候选利用率。
- 稳定重平衡只保证极小评测集两侧非空，不保证类别分层或统计代表性。
- 阈值选择、发布和最终测试仍由容器或宿主显式编排，不是训练服务自动闭环。

13.4 治理与运行

- 当前没有权限、专用审计、自动清理、内置容量测试和生产上线门禁。
- `caller` 不代表已认证身份，不能作为安全边界。
- 结果表会持续增长，验证环境需要外部清表、重建或生命周期策略。
- 旧治理配置会导致未知键错误，升级时必须同步更新外部配置。
- 当前业务日志与测试通过不等于完成真实 FMDB 集群的长期稳定性和灾难恢复验收。

14. 关键类调用关系摘要

入口类	主要依赖	输出或副作用
<code>RahaContainerValidationApplication</code>	Spark、UDF、工作器、三类服务、评测组件	验收摘要和对齐产物
<code>RahaUdfRegistrar</code>	Spark 会话、运行时提交器、UDF 配置	注册三个函数
<code>RepositoryBackedRahaUdfJobSubmitter</code>	任务仓储、FMDB 结果写入器、标识生成器	幂等任务和提交响应
<code>FileRahaUdfJobWorker</code>	共享目录、任务分发器、时钟	完成或失败任务文件
<code>RahaJobOrchestrator</code>	任务仓储、阶段仓储、处理器、失败决策器	通用任务状态与阶段结果
<code>RahaFeaturePreparationService</code>	策略计划、执行和特征服务	可复用策略特征产物
<code>ActiveSamplingOrchestrator</code>	采样服务、标签提供者	多轮任务、顺序和直接标签
<code>RahaTrainService</code>	特征、聚类、传播、训练、模型发布管理	候选模型和训练摘要
<code>RahaDetectService</code>	已发布模型加载器、预测器、结果仓储	单元格检测结果和字段诊断
<code>RvdBatchStrategyExecutor</code>	Spark 数据集、RVD 计划	分批策略摘要和命中
<code>ModelReleaseManager</code>	模型元数据仓储、时钟	候选、发布、停用和回滚状态

入口类	主要依赖	输出或副作用
<code>EvaluationSplitService</code>	全量真值、直接标签坐标、盐值	验证集和最终测试集
<code>ThresholdComparisonService</code>	分数、真值、阈值候选、模型仓储	更新阈值后的模型元数据
<code>SparkSqlFmdbResultWriter</code>	FMDB 网关、模式解析器	任务和检测结果表记录
<code>InMemoryRahaRepository</code>	统一记录存储和事务回调	版本化进程内数据

15. 总结

当前工程仍然具备完整的 Raha 工程化闭环：文件和 FMDB 数据加载、字段画像、OD/PVD/RVD 策略、版本化稀疏特征、可扩展聚类、逐轮主动采样、标签传播、列级训练、模型质量门禁、阈值验证、模型生命周期、生产检测、真值评测、任务状态机、检查点、表级 UDF、文件任务消费和容器黑盒验收。

本轮变化不是简单删代码，而是明确改变了产品边界。五个治理包和相关配置、构造器、测试已退出，工程不再宣称自身提供权限、专用审计、自动清理、容量建议和上线门禁。与此同时，主动采样预算、极小评测切分、采样聚类复用、策略命中释放、RVD 子批和内存 FMDB 血缘都得到修正或优化。

后续最优先的工作应是：为统一仓储提供共享持久化实现，将分区预测器接入默认检测链路，减少策略边界的 Driver 收集，建立文件队列与平台表的一致性恢复机制，并由宿主平台补齐鉴权、审计、生命周期、容量测试和发布门禁。